



Estudiante:

Ismael Encarnación R.

Matricula:

2026-0243

Carrera:

Mecatrónica.

Profesor:

Carlos Antonio Pichardo Viuque

Investigación sobre Codificación de Caracteres

ASCII (American Standard Code for Information Interchange)

Es el estándar de codificación de caracteres más básico y fundamental en la informática. Fue creado para representar texto en equipos que utilizan el alfabeto latino, basándose en el idioma inglés. Utiliza 7 bits para representar cada carácter, lo que permite un total de 128 combinaciones diferentes. Este conjunto incluye letras mayúsculas y minúsculas (A-Z, a-z), dígitos numéricos (0-9), signos de puntuación y una serie de caracteres de control (como salto de línea o retroceso). Su principal limitación es que no incluye caracteres acentuados (como la "ñ" o las tildes) ni caracteres de otros alfabetos como el griego o el cirílico. Por esta razón, su uso hoy en día es limitado, aunque sigue siendo la base sobre la que se construyen la mayoría de los otros sistemas de codificación.

UTF-8 (Unicode Transformation Format - 8 bits)

Es el sistema de codificación de caracteres más utilizado en la actualidad, especialmente en la web. Es una codificación de ancho variable, lo que significa que no todos los caracteres ocupan el mismo número de bytes. Los caracteres del estándar ASCII (los más comunes en inglés) ocupan 1 byte, lo que hace que los archivos de texto plano sean muy eficientes. Para caracteres con acentos, como la "é" o la "ñ", utiliza 2 bytes, y para alfabetos más complejos como el chino o el japonés, utiliza 3 o 4 bytes. Su principal ventaja es el ahorro de espacio para textos en inglés y su alta compatibilidad hacia atrás con ASCII. Es la codificación por defecto en HTML, XML y la mayoría de los lenguajes de programación.

UTF-16 (Unicode Transformation Format - 16 bits)

Esta codificación también es de ancho variable, pero su unidad básica de medida son los bloques de 16 bits (2 bytes). A diferencia de UTF-8, la mayoría de los caracteres comunes utilizan un solo bloque de 2 bytes para representarse. Esto incluye a casi todos los caracteres de los alfabetos más utilizados a nivel mundial. Sin embargo, para caracteres muy antiguos o emojis, necesita utilizar dos bloques de 16 bits (4 bytes en total). Es una codificación muy eficiente en cuanto a procesamiento para sistemas que manejan textos con muchos caracteres no latinos, ya que cada carácter suele tener un tamaño fijo. Su principal desventaja es que desperdicia espacio si se utiliza únicamente para texto en inglés, ya que dobla el tamaño del archivo en comparación con UTF-8. Se utiliza comúnmente en sistemas internos de Windows y en lenguajes como Java.

Investigación sobre Tipos de Archivos

JSON (JavaScript Object Notation)

Es un formato de texto ligero para el intercambio de datos, fácil de leer y escribir para las personas y sencillo de interpretar para las máquinas. Su estructura se basa en dos tipos de elementos: un conjunto de pares de clave/valor (similar a un objeto o diccionario) y una lista ordenada de valores (similar a un array o lista). Las claves deben ir siempre entre comillas dobles ("), y los valores pueden ser cadenas de texto, números, booleanos, objetos, arrays o nulos. Es el formato predilecto para las APIs web (como las de Google o Twitter) debido a su ligereza y rapidez de procesamiento, ya que es nativo del lenguaje JavaScript. Su principal desventaja es que no permite comentarios, lo que dificulta la documentación dentro del propio archivo.

XML (Extensible Markup Language)

Es un lenguaje de marcado que define un conjunto de reglas para codificar documentos de manera que sean legibles tanto para humanos como para máquinas. Su principal característica es el uso de etiquetas personalizadas que describen la naturaleza de los datos, estructurándose en una jerarquía de padres e hijos (similar a un árbol). Por ejemplo, dentro de una etiqueta <persona> podríamos tener <nombre> y <edad>. Es extremadamente versátil y se utiliza en configuraciones de software, ofimática (como en archivos de Word y Excel) y en sistemas de mensajería (SOAP). A diferencia de JSON, permite comentarios y definir reglas estrictas de estructura (mediante DTD o XSD), pero su sintaxis es mucho más verbosa y pesada, lo que lo hace menos eficiente para el intercambio de datos en aplicaciones web modernas.

CSV (Comma-Separated Values)

Es un formato de archivo simple que se utiliza para almacenar datos tabulares, como los de una hoja de cálculo o una base de datos. Básicamente, es un archivo de texto donde cada línea representa una fila de la tabla, y las columnas de esa fila están separadas por un delimitador (comúnmente una coma, aunque también se usa el punto y coma o el tabulador). Este formato es muy popular porque casi cualquier programa de hoja de cálculo (como Excel) o base de datos puede importarlo y exportarlo con facilidad. Es extremadamente ligero y fácil de generar o analizar con código simple. Sin embargo, tiene limitaciones importantes: no admite datos jerárquicos (solo una tabla plana), no define el tipo de datos (todo es texto) y puede presentar problemas si los valores contienen el delimitador o saltos de línea internos.